

FAQ del producto de datos

Entrega final MGE

Ana P. Paredes Rodríguez | Karla Alicia Soto Bedolla

Tecnologías utilizadas

Datos originales: Los datos originales se descargaron del portal oficial y se almacenaron en un bucket de Amazon S3.

Limpieza y transformación: La limpieza y transformación de los datos incluyó:

- Transformar una tabla ancha en una tabla larga, se tenía una columna por mes y se agruparon en una sola variable
- Agrupar por estado-año-mes-tipo de delito
- Calcular la tasa por cada 100,000 habitantes
- Guardar los datos en parquet

Se llevó a cabo en AWS Glue mediante un job de PySpark (se tuvieron 4 particiones)

Datos procesados: Los datos editados se guardaron en una carpeta diferente del mismo bucket de Amazon S3.

Permisos: Se creó un IAM Role para que otorgar permisos y dar acceso seguro a Amazon S3.

Consultas: Amazon Athena se utilizó durante la etapa de preparación de datos para consultar y estructurar la información almacenada en Amazon S3, generando las bases finales utilizadas por la aplicación. En producción, Streamlit consume directamente estos datos procesados desde Amazon S3 mediante AWS Wrangler, sin ejecutar consultas en tiempo real sobre Athena.

Modelaje: El modelo PCA y K-means se desarrolló y ejecuta en Amazon SageMaker, aprovechando el ambiente.

Resultados: Los resultados se almacenan en el mismo bucket pero diferente carpeta.

Aplicación interactiva: Se desarrolló una aplicación en Streamlit para consultar y visualizar los resultados del producto de datos. La aplicación permite al usuario explorar de forma interactiva el índice de violencia por estado, hacer cortes temporales y comparar patrones entre estados. Los datos se consumen en formato

parquet, para optimizar la lectura y consumo de recursos, y se consultan en S3 mediante AWS Wrangler. Esta interfaz permite a los usuarios no técnicos interactuar con los resultados del modelo sin acceder directamente a Athena, SageMaker o a los archivos procesados.

Versionamiento y reproducibilidad: Todo el proyecto se encuentra en un repositorio en Github

¿Cómo se utiliza la solución?

El pipeline se ejecuta corriendo *python run_pipeline.py* desde la raíz del repositorio. Este orquestador dispara el job de Glue que transforma los datos crudos, espera a que termine y luego ejecuta el modelo de PCA y K-means. Los resultados se guardan automáticamente en S3 y quedan disponibles para que la aplicación de Streamlit los consuma. El usuario final no interactúa con el pipeline (solamente accede a la aplicación web desplegada en ECS con AWS Fargate).

¿Cómo se adquieren y usan los datos?

Los datos provienen de dos fuentes oficiales. Los registros de incidencia delictiva que son publicados mensualmente por el Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública y cubren el período de enero 2015 a diciembre 2025, con desagregación por estado, tipo de delito, subtipo, modalidad, sexo y rango de edad. Los datos de población estatal provienen de proyecciones del CONAPO para 2015 – 2027. Ambas bases de datos se almacenan en S3 como la fuente de verdad del pipeline. De ahí, los llama el pipeline para su transformación, análisis y generación de resultados, que posteriormente son visualizados en la aplicación de Streamlit. En una iteración futura, se automatizará la extracción mediante web scraping.

¿Qué tipo de analítica o inteligencia se aplica?

El producto aplica dos técnicas de machine learning no supervisado: PCA y K-means. El primero, se conoce como Análisis de Componentes Principales (PCA) y se realizó sobre las tasas de los 13 tipos de delito por estado. La lógica detrás es que, en lugar de asignar pesos arbitrarios a cada delito, PCA encuentra las combinaciones que mejor explican la varianza entre estados (en este caso, los primeros 5 componentes principales capturaban el 70% de la variación total). El score de violencia se construye como una combinación ponderada de esos 5 componentes, donde cada

uno pondera según la varianza que explica. Después decidimos normalizar a una escala de 0 a 100 para tener una interpretación sencilla.

El segundo, K-means, agrupa los 32 estados en 4 niveles de violencia (bajo, medio, alto y crítico) basándose en su score. Así los límites entre los niveles no son arbitrarios, son definidos por los mismos datos.

Inputs y outputs del producto

Los inputs del pipeline son dos archivos CSV con datos oficiales:

1. El registro de incidencia delictiva por estado y mes (2015 – 2025)
2. Proyecciones de población estatal por año

Los outputs son dos archivos parquet almacenados en S3:

1. *Violence_scores.parquet*: tiene el índice de violencia promedio histórico, el nivel y el cluster de cada estado
2. *Violence_score_yearly.parquet*: tiene el índice de violencia por estado y año para la visualización de series de tiempo.

Estos outputs son utilizados directamente por la aplicación de Streamlit

¿Cómo consume el usuario final los outputs?

El usuario final consume los outputs al visualizar la aplicación web desarrollada en Streamlit, sin necesidad de descargar datos o realizar el mínimo análisis. Puede simplemente consultar la información y en segundos tener un panorama de la situación actual a través de un mapa nacional, un ranking de estados, la evolución histórica del índice y un resumen individual por estado con su cambio entre 2015 y 2025.

¿Cuánto costaría la solución a un año?

Bajo una configuración mínima disponible 24/7, con la aplicación desplegada en Amazon ECS con AWS Fargate, almacenamiento en Amazon S3 y procesamiento/consultas eventuales mediante Glue, SageMaker y Athena, el costo anual estimado se estima en USD \$650.

Componente	Supuesto	Costo anual aprox.
ECS Fargate	0.5 vCPU, 1 GB RAM, 24/7	USD \$216
Application Load Balancer	bajo tráfico	USD \$393
S3	almacenamiento pequeño, <10 GB	< USD \$5
Glue	ejecuciones ocasionales	< USD \$20
Athena	consultas ocasionales	< USD \$5
SageMaker	uso puntual, no endpoint, 24/7	variable / bajo